

SLM의 선형 어텐션 치환 시 발생하는 최적화-생성 불일치에 관한 연구

황인재¹, 정 원¹, 이재희²

¹동서울대학교 컴퓨터소프트웨어학과 학부생

²동서울대학교 컴퓨터소프트웨어학과 교수

hij021122@gmail.com, londinium0913@gmail.com

A Study on the Optimization-Generation Gap in Linear Attention Substitution of SLMs: Focusing on Kimi Delta Attention Post-hoc Transfer

In-Jae Hwang¹, Won-Jeong¹, Jae-Hee Lee²

¹Dept. of Computer Software, Dong-Seoul University

²Dept. of Computer Software, Dong-Seoul University

요약

최근 긴 문맥 처리의 중요성이 대두됨에 따라 선형 및 하이브리드 어텐션 구조가 주목받고 있다. 그러나 사전 학습된 소형 언어 모델(SLM)의 셀프 어텐션을 사후 전이(Post-hoc Transfer) 방식으로 치환했을 때, 자기회귀 생성(Autoregressive Generation) 성능이 유지되는지에 대해서는 체계적인 분석이 부족한 실정이다. 교사 강제(Teacher Forcing) 학습이 매 시점 정답 토큰을 입력으로 제공하는 반면, 자기회귀 생성은 직전 출력을 다음 입력으로 재사용한다. 이로 인해 두 방식은 오차 누적 구조가 근본적으로 상이하며, 학습 손실의 감소가 곧 생성 성능의 복원으로 이어진다고 단정할 수 없다. 본 연구에서는 Phi-tiny-MoE-instruct, Qwen3-1.7B-Base, Llama-3.2-1B에 KDA(Kimi Delta Attention) 기반 사후 전이를 수행하고, 통제 모델과의 최적화-생성 불일치(Optimization-generation Gap) 및 생성 실패 유형 분류의 두 관점에서 분석하였다. 모든 모델에서 교사 강제 손실(Teacher Forcing Loss)은 하락하였으나 KDA 치환 모델만 자기회귀 생성에 실패하였으며, 이는 학습 손실 감소만으로는 사후 구조 치환의 생성 능력 복원을 보장할 수 없음을 시사한다.

1. 서론


트랜스포머(Transformer) 기반 언어 모델은 셀프 어텐션(self-attention)의 연산 복잡도가 시퀀스 길이의 제곱에 비례하여 증가하므로, 긴 문맥(long-context)을 처리할 때 연산 비용이 기하급수적으로 증가한다는 한계가 있다[1]. 2025년 이후, Kimi Linear[1]의 델타 규칙(Delta Rule) 기반 KDA 구조, LdCATs[8]의 어텐션 전이(Attention Transfer), MOHAWK[3]의 단계적 증류(Progressive Distillation) 등 선형 어텐션(linear attention) 및 사후 전이(Post-hoc Transfer) 방식의 연구가 진행되고 있다. 다만, Kimi Linear는 사전 학습 단계에 KDA를 통합한 사례이며, LdCATs와 MOHAWK는 사후 전이의 학습 효율을 보고하였으나 SLM 규모에서의 자기회귀(Autoregressive) 생성 품질은 직접 평가하지 않았다. HALO[2]는 Qwen3 KDA 사후 전이의 기울기 노름(Gradient Norm) 발산을 보고하는 데 그쳤으며, 생성 단계의 성공 여부는 다루지 않았다. 그러나, 교사 강제(Teacher Forcing) 학습은 매 시점 정답 토큰을 입력으로 제공하는 반면, 자기회귀 생성은 직전 시점의 모델 출력을 다음 입력으로 재사용하므로, 두 방식의 오차 누적 구조는 근본적으로 상이하다. 즉, 교사 강제 손실(loss)의 감소가

곧 자기회귀 생성 능력의 복원을 보장하지 않는다. 특히 SLM은 파라미터(parameter) 수가 제한적이어서, 대규모 어텐션 치환이 사전 학습된 표현(representation)을 비가역적으로 손상시킬 위험이 크다. 따라서, SLM에서 사후 전이 기반 KDA 치환이 자기회귀 생성 능력까지 복원하는지 검증할 필요가 있다.

본 연구에서는, 대표적인 SLM 가운데 Phi-tiny-MoE-instruct[5], Qwen3-1.7B-Base[6], 및 Llama-3.2-1B[7]를 대상으로, 사후 전이 기반 KDA 치환에서 발생하는 실패 양상을 체계적으로 분석하였다. 본 연구에서 수행한 분석 방식은 (1) 미치환 통제 모델과의 최적화-생성 불일치(Optimization-Generation Gap) 비교 (2) 생성 실패 유형을 분류 2가지 측면에서 실험을 통해 연구를 진행하였다.

2. 실험 방법 및 설정

(그림 1)은 본 연구에서 대표적인 3개의 SLM 모델에서 수행한 사후 전이 기반 KDA 치환 구조를 나타낸다.



(그림 1) 3개 모델별 사후 전이 기반 KDA 치환 구조

2.1 KDA 치환 구조

KDA는 표준 셀프 어텐션과 달리, 상태 행렬을 시간 축으로 누적·갱신하는 선형 어텐션 모듈이다. 시점 t 에서의 상태 갱신 및 출력은 식(1), (2)와 같이 정의된다.

$$S_t = \exp(g_t) \odot S_{t-1} + \beta_t \cdot k_t^\top v_t \quad (1)$$

$$o_t = q_t \cdot S_t \quad (2)$$

여기서 $S_t \in \mathbb{R}^{d \times d}$ 는 시점 t 의 상태 행렬이며, g_t 는 이전 상태의 감쇠(Decay)를 로그 공간(Log-Space)에서 조절하는 게이트(Gate)이다. β_t 는 현재 입력의 반영 강도를 조절하는 게이트이며, k_t v_t 는 각각 키(Key)와 값(Value) 벡터이다. 식 (1)에서 $\exp(g_t)$ 는 감쇠 게이트를 지수 변환하여 이전 상태에 곱하고, $\beta_t k_t^\top v_t$ 는 현재 시점의 키-값 외적(Outer Product)을 가중하여 상태에 누적한다. 식 (2)에서 출력 o_t 는 질의(Query) 벡터 q_t 와 갱신된 상태 행렬의 곱으로 산출된다. 본 연구에서는 복사된 가중치 위에 단축 합성곱(Short Convolution), 게이팅 프로젝션(Gating Projection), 델타 규칙 기반 상태 갱신(Delta-rule-based State Update), 및 게이트 RMSNorm 출력(Gated RMSNorm Output)을 추가하여 KDA 모듈을 구성한 (그림 1)에서 확인할 수 있듯이, 레이어(Layer)치환은 3:1 방식으로 수행한다.

2.2 실험 설정

실험 대상 모델은 Phi-tiny-MoE-instruct [5](32레이어, 3.82B 파라미터, MoE, 24개 치환), Qwen3-1.7B-Base [6](28레이어, 1.7B 파라미터, 밀집(dense), 21개 치환), 및 Llama-3.2-1B [7](16레이어, 1.2B 파라미터, 밀집, 12개 치환)이다. 나머지 레이어는 원래의 셀프 어텐션을 유지하였다. 학습 데이터는 Long, General, Logic의 3-way 혼합이며, Qwen 기준 최종 학습 윈도우(window) 170,083

개, 검증(Validation) 윈도우 1,000개를 사용하였다. 모든 모델은 최대 시퀀스 길이 4,096 토큰, 배치 크기 (Batch size) 1, 기울기 누적(Gradient Accumulation) 4로 학습하였다. Phi는 게이트만 학습하는 1단계(G_only) 후 KDA 전체 파라미터를 학습하는 2단계(Full_KDA)로 전환하였다. Qwen과 Llama는 Full_KDA 설정을 사용하였다. Qwen에서는 추가로 1:1 치환 비율 및 로짓 수준 지식 증류(Logit-level Knowledge Distillation, KD) [3, 4] 분기를 포함하였다. 통제 실험에서는 동일한 데이터와 학습 파이프라인을 유지하되, 어텐션 교체는 수행하지 않았다. 평가는 검증 교차 엔트로피(Cross-Entropy, CE) 기반 교사 강제 평가와, 산술 질의·자기소개·완성형 프롬프트를 이용한 생성 평가로 구분하였다. 생성 결과는 정상(Intact), 비 붕괴(Non-collapse), 저하(Degraded), 및 붕괴(Collapsed)의 네 등급으로 분류하였다.

3. 실험 결과 분석

<표 1>은 세 모델의 분기별 교사 강제 손실 변화 및 생성 상태를 요약한 것이다.

<표 1> 모델별 분기별 교사 강제 손실 변화 및 생성


Backbone	Branch	Start eval	final	Drop	Generation
Phi-tiny-MoE-instruct					
phi	Original(pre-trained)	N/A	1.259	N/A	intact
phi	3:1 KDA, main long run	4.56	4.25	6.8	collapsed
phi	3:1 KDA, high-LR	4.16	3.8	8.65	collapsed
phi	3:1 KDA, resumed high-LR	3.74	3.56	4.81	collapsed
Qwen3-1.7B-Base					
Qwen	no-KDA control(300step)	1.0417	0.8603	17.41	intact
Qwen	3:1 KDA, CE-only(100step)	13.6741	8.5635	37.37	collapsed
Qwen	3:1 KDA, CE+KD(epoch)	17.4991	15.8189	9.6	collapsed
Qwen	1:1 KDA, CE+KD(epoch)	16.6836	15.7344	5.69	collapsed
Llama-3.2-1B					
Llama	no-KDA control(300 step)	1.5576	1.2157	21.95	non-collapse
Llama	3:1 KDA, CE-only(100step)	10.708	9.5626	10.7	degraded
Llama	3:1 KDA, CE-only(epoch)	4.9751	4.1507	16.57	collapsed

실험 결과를 최적화 생성 불일치와 생성 실패 유형 분류로 나누어 분석하고자 한다.

3.1 최적화-생성 불일치

Phi-tiny-MoE에서는, 원본 모델의 검증 CE가 1.259이며 자기회귀 생성이 정상임을 확인하였다. KDA 치환 후 교사 강제 CE는 최선 분기(Resumed High-LR)에서 3.56까지 감소하였다. 그러나, 세 분기 모두에서 자기회귀 생성은 붕괴 상태를 유지하였으며, 원본 대비 CE 격차는 최소 2.30(3.56 - 1.259)으로 해소되지 않았다. Qwen3-1.7B에서는, 통제 분기의 검증 손실이 1.0417에서 0.8603으로 17.41% 감소하며 정상 생성을 유지하였다. 반면, 3:1 KDA CE 전용 분기(8.5635), 지식 증류 분기(15.8189), 및 1:1 치환 분기(15.7344) 모두에서 생성은 붕괴 상태를 유지하였다. 통제 분기가 동일 설정에서 정상

생성을 유지하였으므로, 생성 실패의 원인은 KDA 치환 자체이다. Llama-3.2-1B에서도, 통제 분기는 검증 손실이 1.5576에서 1.2157로 21.95% 감소하며 비붕괴 상태를 유지하였다. 반면, 3:1 KDA 분기는 1 에포크(Epoch) 후 검증 손실이 4.1507로, 통제 대비 3.41배 높았으며, 생성은 붕괴 상태로 악화되었다. HALO[2]에서도 KDA 적용 시 기울기 노름 발산이 보고되었으며, 본 연구의 결과와 종합하면 사후 전이 기반 KDA 치환의 취약성이 실험한 세 SLM에서 공통적으로 관찰됨을 확인하였다. (그림 2)는 Llama-3.2-1B에서 미치환 통제 모델과 3:1 KDA 분기의 최종 검증 손실 차이를 나타낸다.



3.2 생성 실패 유형 분류

관찰된 생성 실패는 세 유형으로 분류된다. 첫 번째, 반복(Repetition) 유형이다. Llama 3:1 KDA 50스텝(Step) 체크포인트(Checkpoint)에서 동일 구(Phrase)의 무한 반복이 관찰되었다. 두 번째, 붕괴(Collapse) 유형이다. Qwen 3:1 KDA 지식 증류 300 스텝 체크포인트에서 입력 언어와 무관한 다국어 혼합 출력이 관찰되었으며, 토큰 간 의미적 연결이 완전히 소실되었다. 세 번째, 무의미(Nonsense) 유형이다. Llama 1 에포크 체크포인트 및 Qwen 1:1 KDA 1 에포크 체크포인트에서 무의미 문자열이 지속되었으며, 치환 비율 완화와 학습 예산 확대로도 생성 복원에 실패하였다. 반면, 통제 모델은 동일 프롬프트에 대해 자연스러운 완성을 생성하였으며, 생성 실패가 KDA 치환에 기인함을 확인하였다. 세 유형의 실패는, 학습 초기에 반복 유형으로 시작하여 학습이 진행됨에 따라 붕괴 및 무의미 유형으로 전이되는 경향을 보였다. 이는, KDA 모듈의 상태 갱신이 자기회귀 추론 시 오차를 누적하여 발산하는 구조적 취약점을 의미한다. <표 2>는 모델별 생성 실패 유형 및 대표 출력 결과를 나타낸다.

<표 2> 모델별 생성 실패 유형 및 대표 출력 결과

Failure Type	Model / Branch	Prompt	Output (truncated)
intact	Llama control(step-300)	Hello my name is	Kelsey and I am a 2018 graduate of the University of Wisconsin-Madison...
intact	Llama control (step-300)	3+5=	8, 4+6=10, 5+7=11, 6+8=12
intact	Llama control (step-300)	I am an AI	researcher at the University of Oxford. I am interested in the intersection of AI...
repetition	Llama 3:1 KDA(step-50)	I am an AI	and I, I, the following the following the following the following String...
repetition	Llama 3:1 KDA(step-50)	3+5=	atron 1.
collapsed	Qwen 3:1 KD (step-300)	자기소개 해줘	チン又ca我番lestONGl aster...
collapsed	Qwen 3:1 KD (step-200)	3+5는 얼마야?	顛&it0s. feam...
Nonsense	Llama 3:1 KDA (epoch-1, ckpt-42521)	Hello my name is	nyr.
Nonsense	Qwen 1:1 KD (epoch-1, ckpt-42521)	자기소개 해줘	sule(uref4Table-ibions&entinn0率...
Nonsense	Llama 3:1 KDA (epoch-1, ckpt-40000)	3+5=	ney, the most of the most impalum, the 11s, the 11s, the 11

4. 결론

본 연구에서는, Phi-tiny-MoE-instruct[5], Qwen3-1.7B-Base[6], 및 Llama-3.2-1B[7]의 세 SLM을 대상으로, 사후 전이 기반 KDA 치환의 실패 양상을 체계적으로 분석하였다. 세 모델 모두에서 교사 강제 손실은 감소하였다. 그러나, 자기회귀 생성은 반복, 붕괴, 및 무의미 출력으로 실패하였으며, KDA 미적용 통제 모델만이 정상 생성을 유지하였다. 본 논문은, 유효 배치 크기4의 소규모 학습 예산에서 실험하였으며, KDA 구조와 사후 전이 방식의 효과를 분리하지 못하는 한계가 있음을 실험을 통해 검증하였다. 향후 연구로, 단계적 치환 비율 완화, 온-폴리시 증류(On-policy Distillation)[4], KDA 외 선형 어텐션 구조와의 비교, 및 생성 친화적 학습 전략을 통해 사후 전이 기반 구조 치환의 안정성 확보를 위한 연구를 진행하고자 한다.

참고문헌

[1] Kimi Team, “Kimi Linear: An Expressive, Efficient Attention Architecture,” arXiv:2510.26692, 2025.

[2] Y. Chen et al., “Hybrid Linear Attention Done Right: Efficient Distillation and Effective Architectures for Extremely Long Contexts,” arXiv:2601.22156, 2026.

[3] A Bick et al., “Transformers to SSiMs: Distilling Quadratic Knowledge to Subquadratic Models,” in NeurIPS 2024.

[4] R Agarwal et al., “On-Policy Distillation of Language Models: Learning from Self-Generated Mistakes,” in ICLR 2024.

[5] M. Abdin et al., “Phi-3 Technical Report: A Highly Capable Language Model Locally on Your Phone,” arXiv:2404.14219, 2024.

[6] A. Yang et al., “Qwen3 Technical Report,” arXiv:2505.09388, 2025.

[7] A. Grattafiori et al., “The Llama 3 Herd of Models,” arXiv:2407.21783, 2024.

[8] M. Zhang et al., “LoLCATs: On Low-Rank Linearizing of Large Language Models,” in ICLR 2025.